

搜索，即 test-time compute

肖涵

Elastic 副总裁



微信



训练侧已经卷平，推理侧的账没人算过



模型这边

榜单上挤满了人，第一名和第十名差几个千分点。

换谁家的 embedding，效果都差不多。

链路这边

召回、精排、混合检索、查询改写——该有的组件，十年前就都有了。

于是大家的结论

搜索是个成熟行业，剩下的都是工程活，值得投入的地方在别的方向上。



搜索，本来就是一种
test-time compute。



给你一块 GPU，
你把它花在训练时，
还是推理时？

一句话：**不去训一个更大的模型，而是让手上这个模型，在回答每个问题时多干一点活。**训练阶段的钱已经花完了，这笔新的开销花在推理这一刻。

Best-of-N

采样多个候选答案，选出其中最好的一个。

Self-consistency

让模型把推理过程走多遍，取出现次数最多的答案。

Verifier search

用一个判分器在候选里搜索，投入的算力越多，结果越好。

让机器人在一手扑克上多想 20 秒，effect 相当于把模型放大 10 万倍、再多训 10 万倍的时间。

Noam Brown, OpenAI, 2024

20 秒，换 10 万倍。

这个兑换比例一旦成立，问题就从「模型够不够大」，变成了「你舍不舍得在推理时多花这一点」。



ICML 2026, 韩国首尔, Noam Brown 在讲 test-time compute。



01 | 搜索本来就在推理时花算力

多跑几遍，跑得更深一点，然后看看能换回来什么

向量召回一遍，精排再来一遍，查询改写之后又是一遍，多路结果还要融合。这些环节没有一个是
在训练阶段完成的，**全都发生在用户按下回车之后**。这就是 test-time compute，只是我们一直管它
叫「搭链路」。

A

Deeper pass: 把这次前向读透

同一次前向，不只取最后那个池化向量，
把中间的 patch、token 全读出来用。**新
信息：从这次前向里抄回来的。**

B

More passes: 再跑几遍

同一个冻结模型，换新的视角再编码一
次。把文档切成句子，把图片切成 crop。
新信息：从输入里新拿到的。

C

Calibration: 只变换已有的向量

白化、图传播、最优传输、EM——在**同一
批数**上做更花哨的数学。免训练文献大部
分在这一类。**新信息：没有。**

三类用的是同一个冻结模型，区别只在**什么东西进了这次计算**。外面还有一层：让 agent 自己把这些串成链
路（第 05 章）。

一直以来

推理时间是模型的一个属性

延迟写在 SLA 里，超了就上不了线。它不参与交易——想更准，只能回去换个更大的模型。


改写成

这个 TALK 里


推理时间是一种货币

模型不换、权重不动，只把预算从 10ms 提到 100ms，它能买到什么？

before



after



买到

相关性

同一个任务，排得更准

冻结



买到

新能力

压根没被训练过的事

01

向量模型的 TTC

编码器冻住不动，只在推理期把同一批向量重新组合，相关性就能往上走。

换到的是 · 相关性

02

重排模型的 TTC

召回之后再上一段模型，让候选在同一个上下文里互相比。极端情况下，索引可以整个删掉。

换到的是 · 精度

03

用 TTC 换新能力

同样冻结的模型，这次不求它更准，而是让它做一件训练时根本不存在的任务。

换到的是 · 新能力

04

模型之外的 TTC

算力花在 agent 的循环里，由它自己决定先搜什么、用哪个工具、要不要再来一轮。

换到的是 · 召回 + 精度



02 | 向量模型的 test-time compute

编码器冻住不动，只在推理期重新组合它已经算出来的东西

单向量 COSINE



$$\cos(q, d)$$

一篇文档压缩成一个向量

最省算力的做法

句子级 MAXSIM




$$\max_s \cos(q, s)$$

还是那个模型，把文档切成句子各算一遍

同一个模型，多算几遍

COLBERT 多向量




$$\sum_i \max_j \cos(q_i, d_j)$$

每个 query token 对全部 doc token 取 max

需要专门的多向量模型

同一批向量，十二档越算越准的组合




BidirZScore c=1.2



SentMaxSim c=2.2




AdaptGranularity c=2.7




CoverageTriple c=3.7



LexicalHybridRRF c=3.9



CrossRoundRRF c=3.9



DiverseDualCtx c=5.6



ConsensusRocchio c=6.4



NegContrastive c=7.2



MomentumProg c=9.8




GraphCentrality c=12.2



FisherStability c=14.7



大多数「任务 × 编码器」组合都拿到了提升。而涨得最好的是右边两块——gemma-300m 和 qwen3-0.6b 完全没参与过发现。



144

搜出来的程序总数，全部是对同一批冻结向量的免训练重组

12


落在 Pareto 前沿上，从最便宜的一档排到最贵的一档

这也是一条标准的 test-time compute scaling 曲线，而它发生在一个冻结的小模型上：越往右算得越多，精度就越往上走。




03 | 重排是最直接的 test-time scaling

召回给你一堆候选，重排再花一次算力，把它们放在一起比一遍



Omni 里没有 ANN 索引，一次查询要扫全库。建一个图索引，光链接就要每行 256 字节，四百万 chunk 时是 0.95 GB，**接近查询要扫的矩阵的三倍**，而且持续编辑的语料会不断让它失效。


所以同一个空间存两份：**扫描读 1 bit 副本**，**精确向量只有短名单才碰**。粗排分数只决定谁进短名单，不必准，只要短名单够宽；**最终排序由精确重算说了算**。候选集是 $\min(4096, \max(1024, \text{topK} \times 32))$ 。



副本只有精确向量的十六分之一宽；青色是一次查询真正读到的部分。

双塔 bi-encoder

召回



每篇文档的向量，是在别的文档还不存在的时候就算好的。四篇各打各的分，谁也没见过谁。便宜，能扫全库。

listwise 重排

精排



query 和最多 64 篇候选放进同一个上下文，彼此可见。三段都提到延迟时，模型能判断哪一段真的回答了问题。


同样 0.6B 参数，listwise 的 jina-reranker-v3 明显甩开双塔式的 bge-reranker-v2-m3 和 Qwen3-Reranker-0.6B。差距来自让候选互相可见，不是来自更大的模型。



一页文档，多算一遍比建索引更划算




GITHUB



常规做法是把每个 chunk 都 embed、存向量、再用 ANN 查回来。但索引是靠很多次查询摊薄成本的，而一页文档只活在这一次浏览里。为它建索引，比直接跑一遍前向还贵。

所以这里反过来：**把整页塞进一次 listwise 前向**，答案直接以 <mark> 标回原文，页面自己的 CSS、表格、图都不动。

一百万篇文档仍然需要第一段召回。而**只有一页的时候，该删掉的正是召回这一段。**



问题里没有一个实词出现在它找到的那句话里。

search_web 引擎自带 snippet



Tencent Cloud
<https://intl.cloud.tencent.com> › product

Elasticsearch Service

Tencent Cloud Elasticsearch Service (ES) is a fully managed, elastically scalable cloud-native service with enterprise-grade high availability, ... [Read more](#)



Tencent Cloud
<https://www.tencentcloud.com> › products › tem

Tencent Cloud Elastic Microservice

Tencent Cloud Elastic Microservice (TEM) is a serverless PaaS platform designed for microservice applications. It perfectly combines serverless resources and ... [Read more](#)



Tencent Cloud
<https://intl.cloud.tencent.com> › product › emr

Elastic MapReduce

Tencent Cloud Elastic MapReduce (EMR) provides secure and cost-effective cloud-based Hadoop services featuring high reliability and elastic scalability.



Elastic — The Search AI Company
<https://www.elastic.co> › blog › elastic-tencent-cloud-ai-s...

Elastic and Tencent Cloud AI search technology make ...

Jul 14, 2025 — The Tencent Cloud Elasticsearch Service is a one-stop AI search and log analysis service on the cloud.



Gartner

每条下面那行就是引擎选的 snippet。

search_web_deep meta=deep












04 | 用 test-time compute 换一个新能力

一个只会做检索的模型，从来没学过打标签。这次不求它更准，求它会一件新事



这些标签，全是推理期算出来的



没训练、没请第二个模型、没查词典，全部由推理期的计算得到，而且天然是多语言的。

- | 手上有 一个 **jina-embeddings-v5-omni-nano**，大约 1B，图和文共用一个 768 维空间。
- | 要它干 把图里**每一个**东西都说出来：多标签，而且词表是开放的。
- | 前提是 权重全冻结。它是个检索编码器，**没有标注头，没有分类器，训练时压根没见过这个任务。**
- | 只准用 它自己吐出来的那些数，在上面做推理期计算。别的一概不行。

不训练

不请第二个模型

不用 **WordNet** 和词典

不用正则和词性标注

A

Deeper pass: 同一次前向，读得更深

别只拿那个池化完的向量，把 **patch 级** 的输出全读出来，挨个跟 12.8 万个词打分。

新信息：从这次前向里抄回来

B

More passes: 换个视角，再跑一遍

把图切成若干 crop **重新编码**。小物体在自己那张 crop 里占满画面，不再被整图的池化冲淡。

新信息：从输入里新拿到

C

Calibration: 在已有结果上做文章

白化、最优传输、图传播、EM——在**同一批像素**上做更花哨的数学。

新信息：没有

A 换来一大截，B 再补一小截，C 一样都没换来。

离线，只算一次



每张图



递归：同一个打分函数，把每个 **crop** 当成一张新图再跑一遍

$$S(\ell) = \underbrace{0.3 \left(\langle g, e_\ell \rangle - \mu_\ell^g \right)}_{\text{全局上下文}} + \underbrace{0.7 \left(\max_{p \in P} \langle p, e_\ell \rangle - \mu_\ell \right)}_{\text{patch 证据}} + \underbrace{1.3 \left(\max_{c=1..14} s_\ell(\text{crop}_c) - \mu_\ell \right)}_{\text{多 crop 重编码}}$$

全局上下文：池化向量减掉自己的背景先验。不额外花钱。

A **patch 证据** · Deeper pass：在前向已经产生的那些行上做代数，不额外花钱。

B **多 crop** · More passes：14 次新的前向，看新的像素。

然后 $\ell \in$ 词首过滤后的词表 $\rightarrow$ 向量空间 $\text{NMS} (\tau = 0.6) \rightarrow \text{top-}k$

没有分类头，没有 logits，没有学出来的阈值：三个固定权重、两个背景先验，以及若干次 max。




12.8 万个词的得分，压成几个标签




1 · 原始融合得分

全部 128,260 个 token · $0.7 \text{ patch-max} + 0.3 \text{ global}$



一条光滑的钟形：每个词都跟每张图「有点像」



只用池化向量



A 改读 patch




B 再切几个 crop



一步跨得最大的是 A：把这次前向已经算出来的 patch 读完整。B 再去看新的像素，还能再补一段。

这中间模型一个权重都没动过。



能站住的只有 B。C 那些数学假定图和文在两个空间里，可这儿本来就是一个空间。



前沿上的每一步，都让模型读到了上一步没读到的信息。




05 | 模型之外的 test-time compute

前面几个项目都在模型内部。这一层，算力花在了 agent 的循环里

2025 · Deep research



2026 · 长程任务



调研和执行需要的不是同一种 token。收集材料用便宜的本地模型，昂贵的额度留给真正需要判断力的那一段。

用便宜的 token 把互联网下成一个 zip



GITHUB



给它一个题目和一个 token 预算，它**搜、读、写**循环推进，把互联网上跟这个题目相关的内容**下成一个带引用的 zip**。

关键是 token 的账：探索阶段用自己部署的 Qwen3.6-35B-A3B、Qwen3.8-27B 跑，把昂贵的前沿额度省下来，留给后面真正需要判断力的那一步。


dataroom

下成语料 (.zip)



searchbox


只从这个 zip 里找答案



停止条件是覆盖度达标，不是预算耗尽。

Unlock the Power of Search AI

AI 搜索技术大会




给它一个 dataroom 的 zip，**切断网络**，再问一个问题。自己部署的 Qwen3.6-35B-A3B 在里面跑。它想答上来，只能**用手边的本地工具现搭一条链路**——grep、embed、rerank、相似度、聚类、选多样性。

断网这件事是故意的。**不断网，就分不清它是真的在检索，还是网上碰巧有现成答案。**

正在研究的几个问题

- 它最先调用的是哪个工具？
- 是不是 grep 就够了，稠密检索到底在哪些地方才真有用？
- 提高算力预算，难题上的正确率会不会上升？
- 它搭出来的链路，下次还能不能复用？



多跳难题，逼它真的多搜几轮



GITHUB




简单题对研究 agent 搜索毫无用处：**一次 grep 就能命中的问题，什么方法做出来都一样分**。要评测 searchbox，得先有真正需要搜索才能答的题。

怎么造

把语料先抽成知识图谱，每条事实是一条（主语）- [谓语] ->（宾语）的边，然后去**走图里最长的那些路径**。这些长链条自然就成了**多跳问题**——没有任何单独一段文字能直接回答。

题目从同一份语料里长出来，所以是**私有的、不可能被背过的评测集**。agent 必须真的把事实一环一环连起来，也就必须真的去花那份推理算力。



每条事实一条边，最长路径就是多跳题。

把检索单拎出来，量它值多少算力

前面三个是完整的链路。想知道**检索这一环到底值多少**，得把它单独拎出来：固定一份 Jina 文档语料（210 篇 md 加结构化 json，切成 7777 个 chunk），外面套一个 agent，然后**只给它一个外部工具**。

其余全是 Pi 自带的 read、grep、bash。这样被测的就只有 search_corpus 这一件事，**结果的好坏只能归因于它**。

命中不是答案


返回 {score, path, lines, text}, agent 得自己回原文把段落读完、再 grep 一遍看还有哪儿提到。

没有 SIDECAR

7777×768 的矩阵直接在扩展里算：加载 117ms，单次检索 4.3ms。少一个需要启动、占用端口、可能失效的服务。

联网是开关

默认关。开了才挂上 search_web 和 read_url，于是「翻书」和「上网」可以分开计分。



思考流、工具调用、上下文占用、每段耗时，全部流式开着。

01

dataroom · 把召回做满

便宜的本地 token 把互联网下成一个带引用的 zip。这一步决定了天花板——材料里没有的东西，后面谁也变不出来。

02

searchbox · 把精度做满

断网，只给本地工具，让 agent 在推理期自己组装链路。这一步决定了能从材料里取出多少。

03

知识图谱 · 评测基准

从同一份语料生成多跳难题。前面两步的每一次改动，都靠它来衡量。

04

harness · 单独衡量检索

固定语料，只留一个检索工具。把链路里那一环的贡献单拎出来看。




06 | 推理算力这笔账，合起来看

四块地方，同一笔账



A 模型内：多算几遍

推理时干的	重组已有向量，加一段模型，或把这次前向读透
项目	向量代数重组 · 重排 · 页内检索 · 图像标注
买到的	精度 + 一个全新的能力



B 模型外：工具链

推理时干的	自己决定先搜什么、再用什么
项目	dataroom · searchbox · 知识图谱 · harness
买到的	召回 + 精度

两层，一个赌注：多花推理算力，而不是换个更大的模型。

01 2026 不是做搜索最好的一年，也不是最差的一年。

最好是 2025，deep search / deep research 兴起，一提大模型落地就是它俩。最差是 2024，所有人都去做 RAG，觉得传统检索和 reranker 没用了。2026 注意力转向 long-horizon task，搜索的比重被稀释了——但大模型不盯着这块，反而给我们留出了发挥的空间。

02 test-time compute 是一种思维，不是一项技术。


遇到做不好的事情，先别急着去凑数据、去换更大的模型。先问一句：这件事能不能在推理时解决。

03 test-time scaling 不等于 training-free。

两件事是正交的：一个说推理时花多少算力，一个说权重动不动。最强的 TTC 恰恰是训出来的——listwise 重排得先把模型训成能在一个 context 里比候选，long thinking 得先用 RL 训出来。冻结模型只是最省的那种做法，不是定义。

04 今天的搜索模型和 benchmark，几乎都没把 test-time compute 算进去。

榜单上一个模型就一个分数，默认大家都只允许算一遍。应该报的是一条曲线：横轴推理预算，纵轴精度，看它在这个平面上往哪儿爬。一个点测不出 test-time scaling。






搜索，就是 **test-time compute**。
高质量搜索，就是 **test-time scaling**。

肖涵 · Elastic 副总裁

微信



OMNI



IN-PAGE SEARCH




IMAGE TAGGING



DATAROOM



SEARCHBOX



KNOWLEDGE-GRAPH

