

搜索，即 test-time compute

肖涵

Elastic 副总裁



微信



2026 年，搜索还剩什么可做



模型这边

榜单上挤满了人，第一名和第十名差几个千分点。

换谁家的 embedding，效果都差不多。

链路这边

召回、精排、混合检索、查询改写——该有的组件，十年前就都有了。

于是大家的结论

搜索是个成熟行业，剩下的都是工程活，值得投入的地方在别的方向上。

或者，坚持做训练，把训练做得更重。



搜索，本来就是一种 test-time compute。

这条轴上还有大量空间，而它跟模型规模无关。



test-time compute, 说的是同一笔算力花在哪一端。

给你一块 GPU,
你把它花在**训练时**,
还是**推理时**?

一句话：不去训一个更大的模型，而是让手上这个模型，在回答每个问题时多干一点活。训练阶段的钱已经花完了，这笔新的开销花在推理这一刻。

Best-of-N

采样多个候选答案，选出其中最好的一个。

Self-consistency

让模型把推理过程走多遍，取出现次数最多的答案。

Verifier search

用一个判分器在候选里搜索，投入的算力越多，结果越好。

模型没变，权重一个没动。变的只是你愿意为这一次回答，多花多少算力。

让机器人在一手扑克上多想 **20 秒**，effect 相当于把模型放大 **10 万倍**、再多训 10 万倍的时间。

Noam Brown, OpenAI, 2024

20 秒，换 10 万倍。

这个兑换比例一旦成立，问题就从「模型够不够大」，变成了「你舍不舍得在推理时多花这**一点**」。



01 | 为什么说搜索就是 TTC

多跑几遍，跑得更深一点，然后看看能换回来什么

向量召回一遍，精排再来一遍，查询改写之后又是一遍，多路结果还要融合。这些环节没有一个是
在训练阶段完成的，**全都发生在用户按下回车之后**。这就是 test-time compute，只是我们一直管它
叫「搭链路」。

A

Multi-pass: 多跑几遍

同一个模型，换个角度再编码一次。把文档切成句子分别算，把图片切成局部分别看。**每一遍都会带回上一遍漏掉的东西。**

B

Deeper pass: 跑得更深

同一次前向，不只取最后那个池化向量，把中间的 patch、token 全都读出来用。**算力几乎没多花，信息多拿了一大截。**

C

Compose: 串起来

让 agent 自己决定先 grep 还是先 embed，要不要重排，要不要再搜一轮。**链路本身成了推理期的产物。**

单向量 COSINE



$$\cos(q, d)$$

一篇文档压缩成一个向量

最省算力的做法

句子级 MAXSIM




$$\max_s \cos(q, s)$$

还是那个模型，把文档切成句子各算

一遍

同一个模型，多算几遍

COLBERT 多向量



$$\sum_i \max_j \cos(q_i, d_j)$$

每个 query token 对全部 doc token

取 max

需要专门的多向量模型

中间这一列没有换模型，只是在推理时多算了几遍，效果却接近右边那种需要专门多向量模型的做法。



你花出去的
推理时间

multi-pass · deeper pass · 更长的 agent 循环

买

01 相关性

同一个任务，做得更准

02 新能力

模型压根没被训练过的事，它也能干

搜索的上限不取决于模型有多大，
而取决于你愿意为一次查询付出多少推理算力。

01

向量模型的 TTC

编码器冻住不动，只在推理期把同一批向量重新组合，域内 $\Delta nDCG@10$ 能爬 0.17。

换到的是 · 相关性

02

重排模型的 TTC

召回之后再上一段模型，让候选在同一个上下文里互相比。极端情况下，索引可以整个删掉。

换到的是 · 精度

03

用 TTC 换新能力

同样冻结的模型，这次不求它更准，而是让它做一件训练时根本不存在的任务。

换到的是 · 新能力

04

Agentic search 的 TTC

算力花在 agent 的循环里，由它自己决定先搜什么、用哪个工具、要不要再来一轮。


换到的是 · 召回 + 精度



02 | 向量模型的 test-time compute

编码器冻住不动，只在推理期重新组合它已经算出来的东西

这十二个程序，没有一个是人设计的




BidirZScore $c=1.2$




SentMaxSim $c=2.2$



AdaptGranularity $c=2.7$




CoverageTriple $c=3.7$



LexicalHybridRRF $c=3.9$



CrossRoundRRF $c=3.9$



DiverseDualCtx $c=5.6$



ConsensusRocchio $c=6.4$



NegContrastive $c=7.2$



MomentumProg $c=9.8$



GraphCentrality $c=12.2$




FisherStability $c=14.7$

切句子、z-score 归一、多路融合、质心偏移、构图传播，全部是对同一批冻结向量的重新组合。成本从左往右递增。



每行是十二个程序之一，每列是十九个留出任务之一，四个编码器里三个在发现阶段从未出现。76 个「任务 × 编码器」组合里，有 52 个至少在某个程序下拿到了提升。更有意思的是右边两块：gemma-300m 和 qwen3-0.6b 这两个完全没参与过发现的家族，正格比例反而最高，都是 62%。



144

搜出来的程序总数，全部是对同一批冻结向量的免训练重组

12


落在 Pareto 前沿上，成本从 1.2 倍排到 14.7 倍

域内平均 $\Delta nDCG@10$ 从 **+0.07** 爬到 **+0.24**。这就是一条标准的 **test-time compute scaling** 曲线，而它发生在一个 239M 的冻结小模型上。



03 | 重排：最熟悉的 test-time scaling

召回给你一堆候选，重排再花一次算力，把它们放在一起比一遍



条宽是每行的字节数，条高是行数：副本只有精确向量的十六分之一宽。青色标出一次查询真正读了什么——副本全读，精确向量只读短名单那一段。

Omni 里没有 ANN 索引，一次查询要扫全库。建一个图索引，光链接就要每行 256 字节，四百万 chunk 时是 0.95 GB，**接近查询要扫的矩阵的三倍**，而且持续编辑的语料会不断让它失效。

所以同一个空间存两份：**扫描读 1 bit 副本，精确向量只有短名单才碰**。粗排分数只决定谁进短名单，不必准，只要短名单够宽；**最终排序由精确重算说了算**。候选集是 $\min(4096, \max(1024, \text{topK} \times 32))$ 。

1.76x


50 万行时相对全量精扫的加速，M3 Pro 14 核

9.7 ms

文本查询 p50，M3 Ultra，真实个人文件库

双塔 bi-encoder

召回



每篇文档的向量，是在别的文档还不存在的时候就算好的。四篇各打各的分，谁也没见过谁。便宜，能扫全库。

listwise 重排

精排




query 和最多 64 篇候选放进同一个上下文，彼此可见。三段都提到延迟时，模型能判断哪一段真的回答了问题。

同样 0.6B 参数，jina-reranker-v3 的 BEIR nDCG@10 是 61.94，而双塔式的 bge-reranker-v2-m3 是 56.51、Qwen3-Reranker-0.6B 是 56.28。差距来自让候选互相可见，不是来自更大的模型。

只有一页文档时，把索引删掉



GITHUB



常规做法是把每个 chunk 都 embed、存向量、再用 ANN 查回来。但索引是靠很多次查询摊薄成本的，而一页文档只活在这一次浏览里。为它建索引，比直接跑一遍前向还贵。

所以这里反过来：**把整页塞进一次 listwise 前向**，答案直接以 <mark> 标回原文，页面自己的 CSS、表格、图都不动。

271 ms

104 句 / 52 chunk / 约 3.5K token，一次请求，M3 Ultra

0

索引、向量库、chunk 数据库，一个都不需要

一百万篇文档仍然需要第一段召回。而只有一页的时候，该删掉的正是召回这一段。

The screenshot shows the jina-reranker-v3.5 web interface. On the left, there's a sidebar with a search input field containing "https://jina.ai/news/jina-reranker-v3.5", a question input field with "how did they make it run faster without making the model bigger", and a ranking section with "granularity" set to "sentences" and "highlights" set to "top 1". Below this is a "result" section showing a table with columns "sentences", "chunks", "latency", and "requests". The table has one row with values "104", "52", "271 ms", and "1". Below the table is a "highlight" section showing a snippet of text from the original HTML, with the relevant sentence highlighted in yellow. On the right, the main content area shows the search results, including a code snippet for reranking documents and a "Conclusion" section. The conclusion text is highlighted in yellow, stating that the practical claim of jina-reranker-v3.5 is narrow and testable, and that it closes most of the gap to a 4B generalist reranker, and on BEIR it closes all of it while running faster than the model it replaces. At the bottom, there are "Categories" buttons for "Featured" and "Press release".

提问，答案在原页面里点亮。问题里没有一个实词出现在它找到的那句话里。

search_web

引擎自带 snippet




页面开头，或者只是命中了关键词

引擎挑的那一段，通常是页面开头或含关键词的碎片，未必回答了问题。

search_web_deep

正文级 snippet



读正文、切块，所有页面的所有块进同一次 listwise 调用。任何一页的任何一段，都能直接压过另一页的段落。

为什么必须放在一次调用里

listwise 的分数只在同一个 context 内可比。每页各调一次，页内名次可信，跨页排序几乎是任意的：4 个真实 query 实测，逐页排序与合并排序没有一次完全一致，Kendall tau 只有 0.00 到 0.33。合成一次，调用数还从 $N+1$ 降到 1。

让两种 snippet 同场竞争

正文抽取有时反而更差——只抓到小标题，或在 StackOverflow 上选中了提问而不是回答。所以每个 url 同时投入「正文块」和「引擎原始 snippet」两个候选，谁分高用谁。同一次调用里比，所以不需要阈值。

143 ms

53 个块的页面，jina-reranker-v3.5 单次调用中位延迟。v2-base-multilingual 是 4194 ms，**差 29 倍**，塞不进 10 秒预算

72%

两种 snippet 确有差异的 18 组里，正文块胜出的比例

36%

改按固定句数切块时，某中文维基页面被整块丢弃的比例。按大小切，句子覆盖率回到 100%






多花的是读正文 + 切块 + 一次 listwise 的钱，换回来的是真正回答了问题的那一段。



04 | 用 test-time compute 换一个新能力

一个只会做检索的模型，从来没学过打标签。这次不求它更准，求它会一件新事

这些标签出自一个检索模型



没训练、没请第二个模型、没查词典，全部由推理期的计算得到，而且天然是多语言的。

- | 手上有 一个 **jina-embeddings-v5-omni-nano**，大约 1B，图和文共用一个 768 维空间。
- | 要它干 把图里**每一个**东西都说出来：多标签，而且词表是开放的。
- | 前提是 权重全冻结。它是个检索编码器，**没有标注头，没有分类器，训练时压根没见过这个任务。**
- | 只准用 它自己吐出来的那些数，在上面做推理期计算。别的一概不行。

不训练

不请第二个模型

不用 WordNet 和词典

不用正则和词性标注

前面几个项目都是把它会的事做得更好，这一次是让它做一件根本不会的事。

A**同一次前向，读得更深**

别只拿那个池化完的向量，把 **patch 级** 的输出全读出来，挨个跟 12.8 万个词打分。
算力几乎没多花。

几乎不额外花钱

B**换个视角，再跑一遍**

把图切成若干 crop **重新编码**。小物体在自己那张 crop 里占满画面，不再被整图的池化冲淡。

算力随视角数线性增长

C**在已有结果上再做文章**

白化、最优传输、图传播、EM——在**同一批像素**上做更花哨的数学。

算力全花在数学上

A 读得更深换来 +0.371 mAP，**B** 看新的像素再换来 +0.075。

离线，只算一次



每张图



每一个方框，不是那个冻结模型，就是普通算术。A 把同一次前向读得更透，B 在新的像素上重新编码。

$$S(\ell) = \underbrace{0.3 \left(\langle g, e_\ell \rangle - \mu_\ell^g \right)}_{\text{全局上下文}} + \underbrace{0.7 \left(\max_{p \in P} \langle p, e_\ell \rangle - \mu_\ell \right)}_{\text{patch 证据}} + \underbrace{1.3 \left(\max_{c=1..14} s_\ell(\text{crop}_c) - \mu_\ell \right)}_{\text{多 crop 重编码}}$$

全局上下文：池化向量减掉自己的背景先验。不额外花钱。

A patch 证据：在前向已经产出的那些行上做代数。不额外花钱，+0.371 mAP。

B 多 crop：14 次新的前向，看新的像素。14 倍成本，+0.075 mAP。

然后 $\ell \in$ 词首过滤后的词表 $\rightarrow$ 向量空间 $\text{NMS}(\tau = 0.6) \rightarrow \text{top-}k$

没有分类头，没有 logits，没有学出来的阈值：三个固定权重、两个背景先验，以及若干次 max。




12.8 万个词的得分如何被整理出来



4 · 右尾去重

向量空间 NMS → top-k

token 数 (√ 尺度)



NMS 之前的 top-8: kitty · cat · kitten · chatte · kitt · cats · kittens · cosy, 其实是一个概念


NMS 之后 → kitty · cosy · plush · crib · paw · sleeps



做法	P@1	P@3	R@5	MAP
global pooled	0.433	0.289	0.449	0.264
patch max + global	0.753	0.427	0.631	0.635
softpool	0.773	0.449	0.649	0.608
+ CWR multi-crop	0.813	0.476	0.680	0.710

只用池化向量是 0.264；改读 patch 之后 0.635；再多切几个 crop 重新编码，0.710。

A 类一步就 +0.371，B 类再补 +0.075。这中间模型一个权重都没动过。



能站住的是 B 类：真的去看新的像素。A 类把这次前向读透。

至于 C 类那些更花哨的数学——它们的前提是图和文在两个空间里，可这儿本来就是一个空间。



能带回新信息的算力才换得到精度



75 毫秒把一次前向读透，1 秒钟看十五个视角。前沿线上的每一步，都让模型读到了上一步没读到的信息。

+1.3 ms

每张图打标签的额外耗时，约为编码成本的 3%，与原本就要跑的前向共用一次计算

0.847

精细模式 (5-crop) P@1, Swift/bf16 端口, 基线 0.773

32 帧

视频每 240 秒采样一次，跨空间和时间一起取 max

图片

建索引时一并产出标签，不需要第二次前向。

视频

抽帧后共用同一套 patch 打分逻辑，时间维并入同一次 max。

扫描版 PDF

当图片处理。OCR 无法识别的扫描件，也能用词检索到。

编码器、索引、存储全在那台存着文件的 Mac 上。从一篇实验记录到一个能用的功能，中间只隔着这 3% 的算力。




05 | Agentic search 里的 test-time compute

前面两个项目都在模型内部。这一层，算力花在了 agent 的循环里

2025 · Deep research



2026 · 长程任务



调研和执行需要的不是同一种 token。收集材料用便宜的本地模型，昂贵的额度留给真正需要判断力的那一段。

dataroom: 把互联网下成一个 zip



GITHUB



给它一个题目和一个 token 预算，它**搜、读、写**循环推进，把互联网上跟这个题目相关的内容**下成一个带引用的 zip**。

关键是 token 的账：探索阶段用自己部署的 Qwen3.6-35B-A3B、Qwen3.8-27B 跑，把昂贵的前沿额度省下来，留给后面真正需要判断力的那一步。

dataroom

下成语料 (.zip)




searchbox

只从这个 zip 里找答案



任务实时页面：覆盖度进度、token 消耗、工具调用分布。停止条件是覆盖度达标，而不是预算耗尽。




给它一个 dataroom 的 zip，**切断网络**，再问一个问题。自己部署的 Qwen3.6-35B-A3B 在里面跑。它想答上来，只能**用手边的本地工具现搭一条链路**——grep、embed、rerank、相似度、聚类、选多样性。

断网这件事是故意的。**不断网，就分不清它是真的在检索，还是网上碰巧有现成答案。**

正在研究的几个问题

- 它最先调用的是哪个工具？
- 是不是 grep 就够了，稠密检索到底在哪些地方才真有用？
- 提高算力预算，难题上的正确率会不会上升？
- 它搭出来的链路，下次还能不能复用？



断网循环，画成漫画就是这样




简单题对研究 agent 搜索毫无用处：**一次 grep 就能命中的问题，什么方法做出来都一样分。**要评测 searchbox，得先有真正需要搜索才能答的题。

怎么造

把语料先抽成知识图谱，每条事实是一条 (主语)-[谓语]->(宾语) 的边，然后去**走图里最长的那些路径**。这些长链条自然就成了**多跳问题**——没有任何单独一段文字能直接回答。

题目从同一份语料里长出来，所以是**私有的、不可能被背过的评测集**。agent 必须真的把事实一环一环连起来，也就必须真的去花那份推理算力。



实时图谱：每条事实一条边，最长路径视图会把多跳问题直接挑出来。

前面三个是完整的链路。想知道**检索这一环到底值多少**，得把它单独拎出来：固定一份 Jina 文档语料（210 篇 md 加结构化 json，切成 7777 个 chunk），外面套一个 agent，然后**只给它一个外部工具**。

其余全是 Pi 自带的 read、grep、bash。这样被测的就只有 search_corpus 这一件事，**结果的好坏只能归因于它**。

命中不是答案


返回 {score, path, lines, text}，agent 得自己回原文把段落读完、再 grep 一遍看还有哪儿提到。

没有 SIDECAR

7777×768 的矩阵直接在扩展里算：加载 117ms，单次检索 4.3ms。少一个需要启动、占用端口、可能失效的服务。

联网是开关

默认关。开了才挂上 search_web 和 read_url，于是「翻书」和「上网」可以分开计分。



跑完一轮的样子：思考流、每一次工具调用及其参数、上下文占用、自动压缩、每段花了多少秒，全部流式开着。

01

dataroom · 把召回做满

便宜的本地 token 把互联网下成一个带引用的 zip。这一步决定了天花板——材料里没有的东西，后面谁也变不出来。

02

searchbox · 把精度做满

断网，只给本地工具，让 agent 在推理期自己组装链路。这一步决定了能从材料里取出多少。

03

知识图谱 · 评测基准

从同一份语料生成多跳难题。前面两步的每一次改动，都靠它来衡量。

04

harness · 单独衡量检索

固定语料，只留一个检索工具。把链路里那一环的贡献单拎出来看。

跟前面几个项目是同一件事，只是换了一层：那边组装的是模型阶段，这边组装的是工具链。都没有把模型换大。



06 | 回到那句话

四块地方，同一笔账




一层在模型里面，一层在模型外面



A 模型内：多算几遍

推理时干的	重组已有向量，加一段模型，或把这次前向读透
项目	向量代数重组 · 重排 · 页内检索 · 图像标注
买到的	精度 + 一个全新的能力



B 模型外：工具链

推理时干的	自己决定先搜什么、再用什么
项目	dataroom · searchbox · 知识图谱 · harness
买到的	召回 + 精度

两层，一个赌注：多花推理算力，而不是换个更大的模型。



01 这次多花的算力，带回了什么新信息？

被池化丢掉的 patch，被缩放丢掉的像素，被单向量抹平的句子结构，被一次 grep 漏掉的那几跳。**说得出带回了什么，这笔算力就花得值。**

02 最便宜的那一档，是不是已经够了？

图像标注里，光是把这次前向读透就吃掉了 +0.371 mAP，之后十五倍的算力只再添 +0.075。**先把这一次前向的输出读完整，通常比再跑十遍更划算。**


03 这笔算力，该花在链路的哪一段？

一页文档不必建索引，一百万篇仍然需要第一段召回；攒料用便宜的本地 token，判断留给昂贵的模型。**同一笔算力，花在不同环节，回报差很多。**

按这三条走，2026 年的搜索**远远没到没事可做的地步。**



搜索，
就是 **test-time compute**。
高质量搜索，
就是 **test-time scaling**。



THANKS

肖涵 · Elastic 副总裁

微信



IN-PAGE SEARCH







IMAGE TAGGING



DATAROOM



SEARCHBOX



KNOWLEDGE-GRAPH

