

— TEST-TIME COMPUTE · 检索 · 冻结模型

×

搜索，是一种 test-time compute

与其把模型换大，不如在推理这一刻
多算几遍

肖涵

Elastic 副总裁



微信



模型这边

榜单上挤满了人，第一名和第十名差几个千分点。

换谁家的 embedding，效果都差不多。

链路这边

召回、精排、混合检索、查询改写——该有的组件，十年前就都有了。

于是大家的结论

搜索是个成熟行业，剩下的都是工程活，值得投入的地方在别的方向上。

这几个月我一直在想这件事。
后来发现，我们可能一直站在一个不太对的角度看它。



搜索，本来就是一种 test-time compute。

看清这一点，很多原本觉得做到头了的地方，会重新变得有事可做。

一句话：不去训一个更大的模型，而是让手上这个模型，在回答每个问题时多干一点活。训练阶段的钱已经花完了，这笔新的开销花在推理这一刻。

Best-of-N

采样多个候选答案，选出其中最好的一个。

Self-consistency

让模型把推理过程走多遍，取出现次数最多的答案。

Verifier search

用一个判分器在候选里搜索，投入的算力越多，结果越好。

模型没变，权重一个没动。变的只是你愿意为这一次回答，多花多少算力。

让机器人在一手扑克上多想 **20 秒**，effect 相当于把模型放大 **10 万倍**、再多训 10 万倍的时间。

Noam Brown, OpenAI, 2024

20 秒，换 10 万倍。

这个兑换比例一旦成立，问题就从「模型够不够大」，变成了「你舍不舍得在推理时多花这**一点**」。



01 | 为什么说搜索就是它

多跑几遍，跑得更深一点，然后看看能换回来什么

向量召回一遍，精排再来一遍，查询改写之后又是一遍，多路结果还要融合。这些环节没有一个是
在训练阶段完成的，**全都发生在用户按下回车之后**。这就是 test-time compute，只是我们一直管它
叫「搭链路」。

A

Multi-pass: 多跑几遍

同一个模型，换个角度再编码一次。把文档切成句子分别算，把图片切成局部分别看。**每一遍都会带回上一遍漏掉的东西。**

B

Deeper pass: 跑得更深

同一次前向，不只取最后那个池化向量，把中间的 patch、token 全都读出来用。**算力几乎没多花，信息多拿了一大截。**

C

Compose: 串起来

让 agent 自己决定先 grep 还是先 embed，要不要重排，要不要再搜一轮。**链路本身成了推理期的产物。**

单向量 COSINE



$$\cos(q, d)$$

一篇文档压成一个向量

起点

句子级 MAXSIM




$$\max_s \cos(q, s)$$

还是那个模型，把文档切成句子各算一遍

这一步就是 TEST-TIME COMPUTE

COLBERT 多向量



$$\sum_i \max_j \cos(q_i, d_j)$$

每个 query token 对全部 doc token
取 max

得换一个多向量模型

中间这一列最有意思：模型一个字节都没改，只是在推理时多算了几遍，就走到了原本得换模型才够得着的位置。



你花出去的

推理时间

买

multi-pass · deeper pass · 更长的 agent 循环

01 相关性

同一个任务，做得更准

02 新能力

模型压根没被训练过的事，它也能干

搜索的上限不取决于模型有多大，
而取决于你愿意为一次查询付出多少推理算力。

01

重排与页内检索

召回之后再上一个模型，把候选放在一起互相比。极端情况下，索引干脆可以不要。

买到的是 · 精度

02

图像标注

一个只会做检索的模型，被推理期的算力改造成了开放词表的标注器。

买到的是 · 新能力

03

Dataroom

用便宜的本地小模型把开放网络啃成一个带引用的 zip，留着贵的 token 干正事。

买到的是 · 召回

04

Searchbox + 知识图谱

把 agent 关进没有网的盒子里，只能自己现搭链路。再用知识图谱给它出多跳难题。

买到的是 · 精度

从模型内部一直做到 agent 链路，代码全部开源。



02 | 最熟的那笔算力：重排

召回给你一堆候选，重排再花一次钱，把它们放在一起比一遍

向量检索里，每篇文档的向量是**在别的文档还不存在的时候**就算好的。可文档相关不相关，本来就是比出来的：三段都提到延迟，哪一段真的回答了问题？重排就是为这件事额外花的一次推理。

召回阶段

每篇文档一个向量，离线算好。**便宜，能扫全库，但每篇都是盲评。**

重排阶段

query 和最多 64 篇候选塞进同一个 131K 上下文，跨文档做自注意力，在每篇的最后一个 token 上读出分数。**每篇都是在跟对手比。**

jina-reranker-v3, 0.6B

61.94

BEIR nDCG@10。同样 0.6B 的 bge-reranker-v2-m3 是 56.51，Qwen3-Reranker-0.6B 是 56.28

0.6B

比生成式的 listwise 重排小一个数量级，却拿到更好的 BEIR

64 篇

一次调用里同时参与比较的候选数量

只有一页文档时，把索引删掉



GITHUB



常规做法是把每个 chunk 都 embed、存向量、再用 ANN 查回来。但索引是靠很多次查询摊薄成本的，而一页文档只活在这一次浏览里。为它建索引，比直接跑一遍前向还贵。

所以这里反过来：**把整页塞进一次 listwise 前向**，答案直接以 <mark> 标回原文，页面自己的 CSS、表格、图都不动。


271 ms

104 句 / 52 chunk / 约 3.5K token，一次请求，M3 Ultra

0

索引、向量库、chunk 数据库，一个都不需要


一百万篇的时候你当然还要第一段召回。而只有一页的时候，该删掉的恰恰是召回。



The screenshot shows a web interface for the jina-reranker-v3.5 model. On the left, there's a sidebar with a search input field containing "how did they make it run faster without making the model bigger". Below the input, there are options for "granularity" (set to "sentences") and "highlights" (set to "top 1"). A "search" button is visible. The main content area displays the search results, including a snippet of text from a document about green tea and antioxidants. The snippet is highlighted in yellow, indicating the relevant information. Below the snippet, there's a "Conclusion" section with a paragraph of text. At the bottom, there are "Categories" and "Press release" buttons.

提问，答案在原页面里点亮。问题里没有一个实词出现在它找到的那句话里。

1 bit 扫全库，精确向量只读短名单



条宽是每行的字节数，条高是行数：副本只有精确向量的十六分之一宽。青色标出一次查询真正读了什么——副本全读，精确向量只读短名单那一段。

Omni 里没有 ANN 索引，一次查询要扫全库。所以同一个空间存两份：一份只保留每个坐标符号的 1 bit 副本，扫描读它；精确向量只有短名单才碰。一行 $d/8$ 字节对 bf16 的 $2d$ ，正好十六分之一。

取符号之前先做一次随机 Hadamard 旋转。旋转是正交的，**不改变任何内积，也就不改变排序**，只是把每一维携带的信息摊平到所有维度上，1 bit 才够用。查询侧不压到 1 bit：旋转后拆成**四个位平面**，Metal kernel 用几次 popcount 给一行打分。

粗排分数只决定谁进短名单，所以它不必准，只要短名单够宽。**最终排序由精确重算说了算，成本只跟短名单长度成正比**。候选集是 $\min(4096, \max(1024, \text{topK} \times 32))$ 。

1.76x

50 万行时相对全量精扫的加速，M3 Pro 14 核

9.7 ms






文本查询 p50，M3 Ultra，真实个人文件库



03 | Image tagging: 买一个新能力

一个只会做检索的模型，从来没学过打标签。这次不求它更准，求它会一件新事

这些标签出自一个检索模型



没训练、没请第二个模型、没查词典，全部由推理期的计算得到，而且天然是多语言的。

- | 手上有 一个 **jina-embeddings-v5-omni-nano**，大约 1B，图和文共用一个 768 维空间。
- | 要它干 把图里**每一个**东西都说出来：多标签，而且词表是开放的。
- | 前提是 权重全冻结。它是个检索编码器，**没有标注头，没有分类器，训练时压根没见过这个任务。**
- | 只准用 它自己吐出来的那些数，在上面做推理期计算。别的一概不行。

不训练

不请第二个模型

不用 WordNet 和词典

不用正则和词性标注

前面几个项目都是把它会的事做得更好，这一次是让它做一件根本不会的事。

A**同一次前向，读得更深**

别只拿那个池化完的向量，把 **patch 级** 的输出全读出来，挨个跟 12.8 万个词打分。
算力几乎没多花。

几乎不额外花钱

B**换个视角，再跑一遍**

把图切成若干 crop **重新编码**。小物体在自己那张 crop 里占满画面，不再被整图的池化冲淡。

算力随视角数线性增长

C**在已有结果上再做文章**

白化、最优传输、图传播、EM——在**同一批像素**上做更花哨的数学。

算力全花在数学上

下面几页逐个看这三种花法各自换回了什么。

词表当标签空间



每个 patch 打分



减掉背景先验



去重取头部

01 tokenizer 的词表，直接拿来当标签空间

12.8 万个 token 全部编码成文本向量。不用人工整理标签集——模型认识多少词，就有多少个候选标签，开放词表不需要额外代价。

02 每个 patch 单独打分，再跟全局向量融合

$0.7 \times \text{patch-max} + 0.3 \times \text{global}$ 。小物体不再被整张图的池化冲淡，mAP 从 0.264 直接到 0.635。

03 每个词减掉它自己的先验

高频词与任何一张图的相似度都偏高。减掉 μ_l 之后，剩下的右尾才是真正的证据。

04 词首过滤，再在向量空间里做 NMS

12.8 万压到 2.5 万候选；然后把 kitty / cat / kitten / chatte 这种同义词簇合并成一个概念。




12.8 万个词的得分如何被整理出来



1· 原始融合得分

全部 128,260 个 token · 0.7 patch-max + 0.3 global




一条光滑的钟形：每个词都跟每张图「有点像」



做法	P@1	P@3	R@5	MAP
global pooled	0.433	0.289	0.449	0.264
patch max + global	0.753	0.427	0.631	0.635
softpool	0.773	0.449	0.649	0.608
+ CWR multi-crop	0.813	0.476	0.680	0.710

只用池化向量是 0.264；改读 patch 之后 0.635；再多切几个 crop 重新编码，0.710。

A 类一步就 +0.371，B 类再补 +0.075。这中间模型一个权重都没动过。



能站住的是 B 类：真的去看新的像素。A 类把这次前向读透。
至于 C 类那些更花哨的数学——它们的前提是图和文在两个空间里，可这儿本来就是一个空间。



能带回新信息的算力才换得到精度



75 毫秒读透一次前向，1 秒钟看十五个视角。这条前沿线上的每一步，都是往系统里灌进了新东西。

+1.3 ms

每张图打标签的额外耗时，约为编码成本的 3%，搭在原本就要跑的前向上顺手完成

0.847

精细模式 (5-crop) P@1, Swift/bf16 端口, 基线 0.773

32 帧

视频每 240 秒采样一次，跨空间和时间一起取 max

图片

建索引的时候顺手把标签也产出来，不用第二次前向。

视频

抽帧之后共用同一套 patch 打分逻辑，时间维直接并进 max。

扫描版 PDF

当图片处理。那些 OCR 认不出来的老档案，现在也能用词搜到了。

编码器、索引、存储全在那台存着文件的 Mac 上。从一篇实验记录到一个能用的功能，中间只隔着这 3% 的算力。




04 | 往上一层：让 agent 自己搭链路

前面两个项目都在模型内部。这一层，算力花在了 agent 的循环里

2025 · Deep research



2026 · 长程任务



调研和干活，该用的 token 不是一种。攒料用便宜的本地小模型，贵的额度留给真正需要它的那一段。

dataroom: 把开放网络啃成一个 zip



GITHUB



给它一个 token 预算，它就开始**搜、读、写**，一轮一轮来，直到把这个题目下能找到的东西全部打包成一个**带引用的 zip**。

这个名字是我创业时留下的习惯——当年给投资人准备 data room，把该看的材料一次性理清楚放进去。现在换成给 agent 准备。

关键是 token 的账：探索阶段用自己部署的 Qwen3.6-35B-A3B、Qwen3.8-27B 跑，把昂贵的前沿额度省下来，留给后面真正需要判断力的那一步。

dataroom

攒出语料 (.zip)



searchbox

只从这个 zip 里找答案



任务实时页面：覆盖度进度、token 消耗、工具调用分布。停止条件看的是覆盖够不够，不是钱花完没有。

searchbox: 把 agent 关进没有网的盒子




丢给它一个 dataroom 的 zip，然后**切断网络**，再问一个问题。自己部署的 Qwen3.6-35B-A3B 在里面跑。它想答上来，只能**用手边的本地工具现搭一条链路**——grep、embed、rerank、相似度、聚类、选多样性。

断网这件事是故意的。**不断网，就分不清它是真的在检索，还是网上碰巧有现成答案。**

正在研究的几个问题

- 它第一个伸手去拿的是哪个工具？
- 是不是 grep 就够了，稠密检索到底在哪些地方才真有用？
- 逼它多花算力，难题上会不会有起色？
- 它搭出来的链路，下次还能不能复用？



断网循环，画成漫画就是这样




简单题对研究 agent 搜索毫无用处：**一次 grep 就能命中的问题，什么方法做出来都一样分。**要评测 searchbox，得先有真正需要搜索才能答的题。

怎么造

把语料先抽成知识图谱，每条事实是一条 (主语)-[谓语]->(宾语) 的边，然后去**走图里最长的那些路径**。这些长链条自然就成了**多跳问题**——没有任何单独一段文字能直接回答。

题目从同一份语料里长出来，所以是**私有的、不可能被背过的评测集**。agent 必须真的把事实一环一环连起来，也就必须真的去花那份推理算力。



实时图谱：每条事实一条边，最长路径视图会把多跳问题直接挑出来。

前面三个是完整的链路。想知道**检索这一环到底值多少**，得把它单独拎出来：固定一份 Jina 文档语料（210 篇 md 加结构化 json，切成 7777 个 chunk），外面套一个 agent，然后**只给它一个外部工具**。

其余全是 Pi 自带的 read、grep、bash。这样被测的就只有 search_corpus 这一件事，**好和坏都只能归给它**。

命中不是答案


返回 {score, path, lines, text}，agent 得自己回原文把段落读完、再 grep 一遍看还有哪儿提到。

没有 SIDECAR

7777×768 的矩阵直接在扩展里算：加载 117ms，单次检索 4.3ms。少一个要启动、要占端口、会挂掉的服务。

联网是开关

默认关。开了才挂上 search_web 和 read_url，于是「翻书」和「上网」可以分开计分。



跑完一轮的样子：思考流、每一次工具调用及其参数、上下文占用、自动压缩、每段花了多少秒，全部流式开着。

01

dataroom · 拉满召回

便宜的本地 token 把网络啃成一个带引用的 zip。这一步决定了天花板——材料里没有的东西，后面谁也变不出来。

02

searchbox · 拉满精度

断网，只给本地工具，逼 agent 在推理期自己组装链路。这一步决定了你能从材料里捞出多少。

03

知识图谱 · 说了算的裁判

从同一份语料长出多跳难题。有了它，前面两步的每一次改动才有得比。

04

harness · 单独衡量检索

固定语料，只留一个检索工具。把链路里那一环的贡献单拎出来看。

跟前面几个项目是同一件事，只是换了一层：那边组装的是模型阶段，这边组装的是工具链。都没有把模型换大。



05 | 回到那句话

这几个项目跑完，我更相信这个判断了



一层在模型里面，一层在模型外面



A 模型内：多算几遍

推理时干的 加一段模型，或把这次前向读透

项目 重排 · 页内检索 · 两段漏斗 · 图像标注

买到的 精度 + 一个全新的能力



B 模型外：工具链

推理时干的 自己决定先搜什么、再用什么

项目 dataroom · searchbox · 知识图谱 · harness

买到的 召回 + 精度

两层，一个赌注：多花推理算力，而不是换个更大的模型。

01 先问：这次多花的算力，带回了什么新东西？

被池化丢掉的 patch，被缩放丢掉的像素，被单向量抹平的句子结构，被一次 grep 漏掉的那几跳。能说出带回了什么，这笔钱就花得值。

02 再问：最便宜的那一档，是不是已经够了？

图像标注里，光是把这次前向读透就吃掉了 +0.371 mAP，之后十五倍的算力只再添 +0.075。先把手上这次算完的东西读干净，往往比再跑十遍划算。

03 最后问：这笔算力，该花在哪一段？


一页文档不必建索引，一百万篇仍然需要第一段召回；攒料用便宜的本地 token，判断留给昂贵的模型。同样一笔钱，花错地方就是白花。

按这三条走，2026 年的搜索远远没到没事可做的地步。



搜索是一种 **test-time compute**。
别急着换更大的模型，
先在推理时**多搜一点**。


这几个月我一直在这条路上，
它比我想的要宽。



THANKS

肖涵 · Elastic 副总裁

微信



IN-PAGE SEARCH







IMAGE TAGGING



DATAROOM



SEARCHBOX



KNOWLEDGE-GRAPH

